



UNIVERSIDAD DE MONTERREY

Integración de aplicaciones computacionales

Proyecto 4. Plataforma de Bienestar Laboral y Prevención de Burnout (EQUIPO 03)

Diseño de Arquitectura de Hardware

Integrantes:

Emiliano Pascual Piñales Sánchez #657657

Gerardo Quiroga Ramírez #650313

Ricardo Arath Sánchez Aguirre #583928

Juan Pablo Ramos Salazar #610248

“Damos nuestra palabra que hemos realizado esta actividad con integridad académica”

Contenido

Para actualizar el índice en Word: clic derecho sobre la tabla → Actualizar campos → Actualizar toda la tabla.

1. Propósito y alcance

Este documento define la arquitectura de hardware de la Plataforma de Bienestar Laboral: qué máquinas la ejecutan, cómo se conectan, cómo se aíslan entre sí y por qué tienen el tamaño que tienen.

El dimensionamiento no se tomó de una plantilla. Cada especificación de este documento se deriva de una medición hecha sobre el sistema real, con la base de datos cargada al tamaño de la organización del caso de estudio y con la aplicación ejecutándose. La sección 3 presenta esas mediciones antes de proponer una sola máquina.

El alcance cubre los tres ambientes que exige la rúbrica de evaluación —developer, staging y production— y la plataforma de nube obligatoria del proyecto, Google Cloud Platform con Compute Engine. Los componentes que corresponden a parciales posteriores (microservicios, MongoDB, clúster) aparecen dimensionados como previsión, señalados de forma explícita.

2. Principios de diseño

Cinco principios guían las decisiones de este documento. Cada uno responde a una característica del proyecto, no a una preferencia general.

Principio	Por qué aplica a este sistema
Dimensionar sobre evidencia	Se midió el consumo real antes de elegir el tamaño de cada máquina. Sobredimensionar cuesta dinero; subdimensionar se descubre en la demostración.
Aislar los datos de la red pública	El sistema trata datos personales sensibles. La máquina que los guarda no tiene dirección IP pública, de modo que la separación de identidad y respuestas se sostiene también a nivel de red.
Empezar simple y tener escrito cuándo crecer	Con la carga medida, una instancia por servicio basta. Introducir réplicas o clúster desde el inicio añadiría complejidad sin beneficio; la sección 12 define el momento exacto de hacerlo.
Paridad entre ambientes	Los tres ambientes ejecutan la misma imagen de contenedor. Lo único que cambia son las variables de entorno, para que un problema no aparezca por primera vez en producción.
Servicios gestionados donde tienen sentido	Redis, almacenamiento de objetos y secretos se toman como servicios gestionados en lugar de administrarlos en una máquina propia: reduce trabajo de operación sin comprometer el control.

3. Base empírica del dimensionamiento

Las mediciones se hicieron sobre el esquema completo del proyecto, con la organización del caso cargada a su tamaño declarado, y con la aplicación corriendo bajo Gunicorn.

3.1 Condiciones de la medición

Aspecto	Valor
Motor de base de datos	PostgreSQL 16.13 sobre Linux x86-64
Colaboradores cargados	1,161 en 16 unidades organizacionales
Consentimientos vigentes	951 aceptados vigentes (210 revocaciones registradas)
Respuestas	3,804 encabezados y 19,020 reactivos
Servidor de aplicación	Gunicorn con 4 procesos de trabajo, Flask y psycopg2
Operación ejercitada	Cálculo de agregado protegido con umbral k y mecanismo de Laplace

3.2 Consumo de memoria medido

Este es el dato que determina el tamaño de las máquinas. Se midió la memoria residente de cada proceso con la carga completa en operación.

Componente	Memoria residente	Observación
PostgreSQL (todos sus procesos)	69.9 MB	Con la base cargada y consultas en curso
Gunicorn, proceso maestro	21.7 MB	Uno por máquina
Gunicorn, cada proceso de trabajo	34.0 MB	Cuatro en la configuración probada
Aplicación completa	158.4 MB	Maestro más cuatro trabajadores

Hallazgo relevante: la memoria de PostgreSQL apenas se movió entre el estado en reposo y la ejecución de 312 agregados protegidos, de 69.7 MB a 69.9 MB. La carga de trabajo del sistema no infla la memoria, porque la base completa cabe holgadamente en el área de caché ya reservada.

3.3 Almacenamiento medido

Elemento	Tamaño	Naturaleza
Base de datos del proyecto	12 MB	Cuatro campañas completas
Clúster de PostgreSQL en disco	62 MB	Incluye registro de transacciones y catálogos del motor
Proyección a diez años	~120 MB	Crecimiento lineal por campaña

3.4 Capacidad de proceso medida

Prueba	Resultado	Equivalencia
312 agregados protegidos en lote	1,591 ms	5.1 ms por agregado
Agregado de la unidad más grande	51.6 ms	171 respuestas procesadas
Escritura de bitácora	54.7 ms por 2,000 eventos	≈ 36,600 eventos por segundo
Conexiones simultáneas observadas	6 de 100 permitidas	Sin presión sobre el límite

3.5 Latencia extremo a extremo

El documento de rendimiento anterior declaró como limitación que sus mediciones no incluían la capa de aplicación ni el protocolo HTTP. Esa limitación se cierra aquí: se midió el recorrido completo, desde la petición HTTP hasta la respuesta, pasando por el mecanismo de privacidad diferencial.

Peticiones simultáneas	Latencia media	Latencia p95	Throughput
1	15.6 ms	18.8 ms	64.1 peticiones/s
5	45.4 ms	67.0 ms	106.2 peticiones/s
10	85.9 ms	109.4 ms	111.0 peticiones/s
25	188.0 ms	224.0 ms	117.4 peticiones/s

Interpretación: con cuatro procesos de trabajo el sistema satura alrededor de 117 peticiones por segundo. A partir de ahí el throughput deja de crecer y la latencia aumenta de forma proporcional, que es el comportamiento esperado cuando las peticiones empiezan a hacer cola. Aun con veinticinco peticiones

simultáneas, la latencia del percentil 95 se mantiene en 224 ms, por debajo del objetivo de 500 ms fijado para operaciones de negocio.

4. Inventario de hardware

La plataforma se ejecuta sobre cuatro elementos de cómputo y tres servicios gestionados. El inventario distingue lo que opera en este parcial de lo que se incorpora después.

Elemento	Tipo	Función	Etapas
VM de aplicación	Compute Engine e2-small	Sistema web Flask con Gunicorn	Este parcial
VM de datos	Compute Engine e2-medium	PostgreSQL 16	Este parcial
Balanceador	Cloud Load Balancing	Terminación TLS y punto único de entrada	Este parcial
Caché y sesiones	Memorystore para Redis, 1 GB	Sesiones, tokens revocados, caché de agregados	Este parcial
Almacenamiento de objetos	Cloud Storage	Evidencias y reportes con URLs firmadas	Este parcial
Gestión de secretos	Secret Manager	Contraseñas, llaves de firma, cadenas de conexión	Este parcial
Observabilidad	Cloud Logging y Monitoring	Bitácora de infraestructura y alertas	Este parcial
VM de microservicios	e2-small (previsión)	Servicios REST en contenedores	Segundo parcial
MongoDB	Por definir	Respuestas históricas y telemetría	Segundo parcial
Réplica de lectura	e2-medium (previsión)	Absorber consultas de tablero	Tercer parcial

5. Dimensionamiento justificado

Cada máquina se justifica contra la medición correspondiente. Se declara también el margen, porque un dimensionamiento sin margen explícito no es verificable.

5.1 Máquina de aplicación

Recurso	Medido	Asignado	Margen
Memoria	158.4 MB (4 trabajadores)	2 GB (e2-small)	≈ 12 veces
Procesador	117 peticiones/s con 2 vCPU	2 vCPU	Carga esperada 100 veces menor
Disco	Imagen y registros	20 GB estándar	Suficiente

Por qué e2-small y no una máquina menor. Con 158 MB medidos, una instancia de 1 GB bastaría para la aplicación. Se elige el tipo de 2 GB por dos razones concretas: el sistema operativo y el motor de contenedores consumen alrededor de 300 MB, y durante la generación de reportes la aplicación carga estructuras en memoria que no se ejercitaron en esta medición. El margen absorbe ambas situaciones sin recurrir a memoria de intercambio, que degradaría la latencia de forma notable.

5.2 Máquina de datos

Recurso	Medido	Asignado	Margen
Memoria	69.9 MB en operación	4 GB (e2-medium)	≈ 57 veces
Procesador	5.1 ms por agregado	2 vCPU	Amplio
Disco	62 MB de clúster	20 GB SSD	≈ 320 veces

Por qué e2-medium para una base de 12 MB. La medida sola justificaría la máquina más pequeña del catálogo. La elección responde a tres criterios distintos del consumo actual: primero, con 4 GB se puede asignar un gigabyte al área de caché del motor y mantener la base completa residente en memoria, lo que elimina lectura de disco en el camino crítico; segundo, esta máquina alojará MongoDB en el segundo parcial; tercero, el respaldo y las tareas de mantenimiento del motor compiten por memoria con las consultas, y el margen evita que una tarea de mantenimiento degrade el servicio.

5.3 Configuración recomendada de PostgreSQL

Los valores por omisión del motor no aprovechan la máquina asignada. La configuración propuesta parte del tamaño real de la base.

```
shared_buffers    = 1GB      # la base completa (12 MB) cabe muchas veces
effective_cache_size = 3GB    # el planificador asume disponibilidad de caché
work_mem          = 16MB     # ordenamientos de la vista de consentimiento
maintenance_work_mem = 256MB # respaldos y reconstrucción de índices
max_connections   = 50       # se observaron 6; 50 deja margen amplio
```

La reducción del límite de conexiones de 100 a 50 es deliberada: cada conexión reserva memoria, y con seis conexiones observadas un límite de cien solo abre la puerta a que un error de programación agote la memoria de la máquina.


5.4 Resumen

Máquina	Tipo	vCPU	Memoria	Disco
Aplicación	e2-small	2 (compartidas)	2 GB	20 GB estándar
Datos	e2-medium	2 (compartidas)	4 GB	20 GB SSD
Redis	Memorystore	—	1 GB	—

6. Topología de despliegue

La topología separa el sistema en dos niveles de red: uno accesible desde Internet a través del balanceador, y otro donde viven los datos, sin dirección pública.

Topología de despliegue — ambiente de producción (Google Cloud Platform)



Regla de oro de esta topología: la VM de datos NO tiene dirección IP pública.
Solo la VM de aplicación puede alcanzarla, y solo por los puertos 5432 y 6379.

Figura 1. Topología de despliegue del ambiente de producción.

7. Segmentación de red y reglas de firewall

La segmentación es el control de infraestructura que sostiene las decisiones de privacidad del proyecto. La decisión D-01 separa identidad de respuestas en el modelo de datos; la red hace que esa separación también sea difícil de vulnerar desde fuera.

Segmentación de red y reglas de firewall




Figura 2. Segmentación de red y zonas de confianza.

8. Reglas de firewall declaradas

La política de base es denegar todo el tráfico. Cada regla abre un puerto específico entre dos puntos concretos y se justifica.

Regla	Origen	Destino	Puerto	Justificación
Entrada web	Internet	Balanceador	443	Único punto de entrada público
Balanceador a aplicación	Balanceador	Subred 10.10.1.0/24	8000	Tráfico ya terminado en TLS
Aplicación a datos	Subred 10.10.1.0/24	Subred 10.10.2.0/24	5432	Acceso a PostgreSQL
Aplicación a caché	Subred 10.10.1.0/24	Subred 10.10.2.0/24	6379	Sesiones y caché
Administración	Identity-Aware Proxy	Ambas subredes	22	Acceso administrativo sin exponer SSH
Todo lo demás	Cualquiera	Cualquiera	Cualquiera	Denegado por omisión

Consecuencia práctica: si alguien obtuviera la contraseña de la base de datos, no podría usarla desde Internet. Tendría que estar dentro de la subred de aplicación. Esto convierte una credencial filtrada en un incidente contenido en lugar de una fuga de datos personales.

9. Los tres ambientes

La rúbrica de evaluación exige que el proyecto se ejecute en los ambientes developer, staging y production. Los tres comparten las mismas imágenes de contenedor y se diferencian en infraestructura, datos y operación.




Figura 3. Comparación de los tres ambientes.

10. Almacenamiento, respaldo y retención

10.1 Estrategia de respaldo

Elemento	Frecuencia	Retención	Mecanismo
Base de datos completa	Diaria	7 días	Instantánea del disco persistente
Registro de transacciones	Continuo	7 días	Archivado para recuperación a un punto en el tiempo
Objetos en almacenamiento	Versionado	30 días	Versionado del bucket
Configuración de infraestructura	Por cambio	Histórico completo	Versionada en el repositorio

El respaldo diario con registro continuo permite recuperar el sistema a cualquier momento dentro de la ventana de siete días. Con una base de 12 MB, la restauración completa toma segundos, no horas.

10.2 Objetivos de recuperación

Objetivo	Valor	Fundamento
Tiempo objetivo de recuperación	2 horas	Recrear la máquina desde imagen y restaurar la instantánea
Punto objetivo de recuperación	5 minutos	Límite del archivado continuo del registro de transacciones

10.3 Retención de datos

La política de retención no es una decisión de infraestructura sino una obligación declarada en el aviso de privacidad, y el hardware debe sostenerla: veinticuatro meses para las respuestas de autoreporte y cinco

años para la evidencia de consentimiento. El dimensionamiento de disco de la sección 5 ya contempla ese horizonte.

11. Disponibilidad y tolerancia a fallos

11.1 Análisis por componente

Componente	Si falla	Efecto sobre el servicio
Balanceador	Gestionado	Redundancia provista por la plataforma; sin acción del equipo
VM de aplicación	Indisponible	Interrupción hasta reinicio automático; se elimina al agregar una segunda instancia
VM de datos	Indisponible	Interrupción total del servicio. Es el punto único de falla de esta etapa.
Redis	Indisponible	Se pierden sesiones activas; las personas vuelven a iniciar sesión y las consultas van directo a la base
Almacenamiento de objetos	Gestionado	Redundancia provista por la plataforma

Riesgo aceptado de forma consciente: la máquina de datos concentra identidad, consentimiento y respuestas, y su indisponibilidad detiene el servicio. Para un sistema de encuestas trimestrales con una ventana de aplicación de cinco días, una interrupción de dos horas es tolerable frente al costo de mantener una réplica activa todo el año. La mitigación está planificada para el tercer parcial.

11.2 Ruta de mejora

Etapas	Medida	Qué resuelve
Segundo parcial	Respaldo automático con recuperación a punto en el tiempo	Reduce la pérdida de datos a cinco minutos
Tercer parcial	Réplica de lectura	Absorbe consultas de tablero y sirve de respaldo caliente
Entrega final	Segunda instancia de aplicación	Elimina el punto único de falla de la capa web

12. Cuándo escalar

Escalar sin un disparador definido es adivinar. Cada umbral de esta tabla proviene de una medición de la sección 3, de modo que el equipo puede reconocer el momento en lugar de estimarlo.

Señal observada	Umbral	Acción	Origen del umbral
Peticiones simultáneas sostenidas	Más de 25	Agregar segunda VM de aplicación	Saturación medida en 117 peticiones/s
Latencia p95 de agregado	Más de 300 ms	Activar precálculo al cerrar campaña	Objetivo de nivel de servicio
Memoria usada en VM de datos	Más del 70 %	Subir a e2-standard-2	Evitar memoria de intercambio
Uso de disco	Más del 70 %	Ampliar disco persistente	Ampliación sin detener el servicio
Unidades organizacionales	Más de 50	Precalcular agregados por lote	Techo de consultas por presupuesto

Señal observada	Umbral	Acción	Origen del umbral
Eventos en bitácora	Más de 10 millones	Particionar por rango de fecha	Tamaño de índice manejable

Orden de intervención: aumentar los recursos de una instancia antes que multiplicar instancias. Las mediciones muestran margen suficiente para que el crecimiento previsible de la organización se atienda con escalamiento vertical, que no introduce los problemas de coordinación de estado que trae el horizontal.

13. Seguridad de la infraestructura

Control	Implementación
Aislamiento de red	Los datos viven en una subred sin dirección pública ni ruta de salida a Internet
Cifrado en tránsito	TLS terminado en el balanceador; tráfico interno por red privada del proyecto
Cifrado en reposo	Discos persistentes y almacenamiento de objetos cifrados por la plataforma
Gestión de secretos	Secret Manager; ninguna credencial en el repositorio ni en la imagen del contenedor
Acceso administrativo	Identity-Aware Proxy en lugar de SSH expuesto; sin llaves compartidas entre integrantes
Principio de menor privilegio	Cada máquina opera con una cuenta de servicio que solo puede lo que necesita
Objetos privados	Las evidencias se sirven con URLs firmadas de vigencia limitada, nunca con acceso público
Registro de infraestructura	Cloud Logging conserva los accesos administrativos, separado de la bitácora de la aplicación

Estos controles son de infraestructura y se suman a los de la aplicación —hash de contraseñas, JWT de corta duración, revocación mediante Redis, control de acceso por perfil— descritos en el documento de estrategia de seguridad.

14. Consideraciones económicas

El costo de la infraestructura propuesta depende de la región, del tipo de compromiso de uso y de los precios vigentes, que cambian con frecuencia. Por esa razón este documento no fija cifras: indica qué se debe costear y cómo reducirlo.

Concepto	Consideración
Cómputo	Dos instancias de la familia e2, que es la de menor costo para cargas de uso general
Almacenamiento	40 GB de disco persistente en total, un volumen mínimo
Redis gestionado	La instancia más pequeña disponible, 1 GB
Balanceador	Cargo por regla de reenvío más tráfico procesado
Tráfico de salida	Bajo: el sistema sirve páginas y datos agregados, no contenido pesado

14.1 Medidas de reducción aplicables al proyecto

- Apagar el ambiente de staging fuera del horario de trabajo del equipo.
- Usar los créditos del programa educativo de Google Cloud durante el semestre.
- Mantener el ambiente de developer en las máquinas del equipo con Docker Compose, sin costo de nube.

- Verificar el costo mensual estimado en la calculadora oficial de precios antes de crear los recursos, y volver a verificarlo al cambiar de tipo de máquina.

El equipo debe registrar el costo real observado durante el semestre en el reporte técnico, en lugar de presentar una estimación teórica.

15. Riesgos y limitaciones declaradas

#	Riesgo o limitación	Impacto	Tratamiento
1	La máquina de datos es punto único de falla	Interrupción total	Réplica de lectura en el tercer parcial; respaldo diario mientras tanto
2	Las mediciones se hicieron en una sola máquina, no en Compute Engine	Los valores en la nube pueden diferir	Repetir la medición en staging y registrar el resultado
3	Las instancias de la familia e2 comparten procesador	Variabilidad de latencia bajo carga del vecino	Vigilar el indicador de crédito de CPU; migrar a familia n2 si se observa
4	El costo no está cifrado en este documento	El equipo podría exceder los créditos	Verificar en la calculadora oficial antes de crear recursos y vigilar el consumo
5	No se ha ejecutado prueba de carga con Locust	El comportamiento bajo carga real es una proyección	Ejecutar el plan de pruebas de carga en el tercer parcial
6	El ambiente de producción aún no está desplegado	La rúbrica exige ejecución en los tres ambientes	Desplegar dentro del sprint en curso; es requisito de la demostración

16. Conclusiones

- El dimensionamiento se sostiene en mediciones y no en supuestos: 69.9 MB de memoria para la base de datos, 158.4 MB para la aplicación y 62 MB de almacenamiento, con la organización del caso cargada por completo.
- Dos instancias pequeñas de Compute Engine cubren la carga con un margen de doce veces en la capa de aplicación y de cincuenta y siete veces en la de datos.
- La medición extremo a extremo cierra la limitación declarada en el documento de rendimiento: con veinticinco peticiones simultáneas el percentil 95 es de 224 ms, por debajo del objetivo de 500 ms.
- La segmentación de red lleva la decisión de privacidad D-01 al plano de la infraestructura: la máquina que guarda los datos personales no es alcanzable desde Internet.
- Los tres ambientes exigidos por la rúbrica quedan definidos con su infraestructura, sus datos y su operación, compartiendo las mismas imágenes de contenedor.
- Los umbrales de escalamiento están fijados contra mediciones concretas, de modo que el equipo pueda reconocer cuándo crecer en lugar de estimarlo.
- El riesgo abierto principal es que la máquina de datos constituye un punto único de falla, con mitigación planificada y fechada.